



Data Collection and Preprocessing Phase

Date	22 June 2024
Team ID	739882
Project Title	Income Activities Using Machine Learning
Maximum Marks	6 Marks

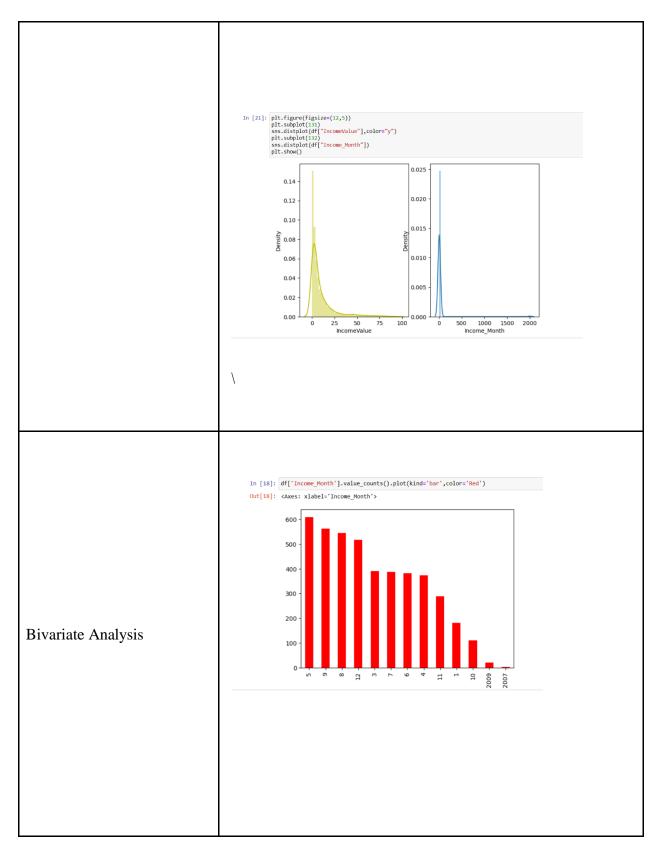
Data Exploration and Preprocessing Report

Dataset variables will be statistically analyzed to identify patterns and outliers, with Python employed for preprocessing tasks like normalization and feature engineering. Data cleaning will address missing values and outliers, ensuring quality for subsequent analysis and modeling, and forming a strong foundation for insights and predictions.

Section	Descr	ipti	on							
		_	ve sta	atistics	<u>:</u>					
	Out[7]:		ADM0_NAME	ADM1_NAME	ADM2_NAME	Income_Category	Income_Month	Income_Year	IncomeValue	Income_DataSource
		count	4370	4022	444	4349	4370.000000	4370.000000	4370	4345
		unique	32	363	68	27	NaN	NaN	3744	32
		top	Senegal	\$South/Amajyepfo	Lanao Del Norte	Labor - Salary/Regular	NaN	NaN	Baseline	WFP VAM Analyse Globale de la Vulnerabilite, d
		freq	256	54	12	370	NaN	NaN	25	256
		mean	NaN	NaN	NaN	NaN	18.535240	1998.965904	NaN	NaN
Data Overview		std	NaN	NaN	NaN	NaN	151.007077	150.455385	NaN	NaN
Data Overview		min	NaN	NaN	NaN	NaN	1.000000	0.350877	NaN	NaN
		25%	NaN	NaN	NaN	NaN	5.000000		NaN	NaN
		50%	NaN	NaN	NaN	NaN	7.000000		NaN	NaN
		75% max	NaN NaN	NaN NaN	NaN NaN	NaN NaN	9.000000	2012.000000	NaN NaN	NaN NaN
			, con	, and			2003.500000	2011.00000		
Univariate Analysis										

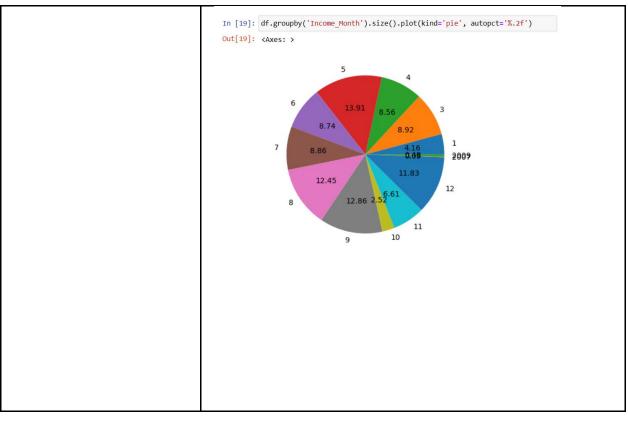


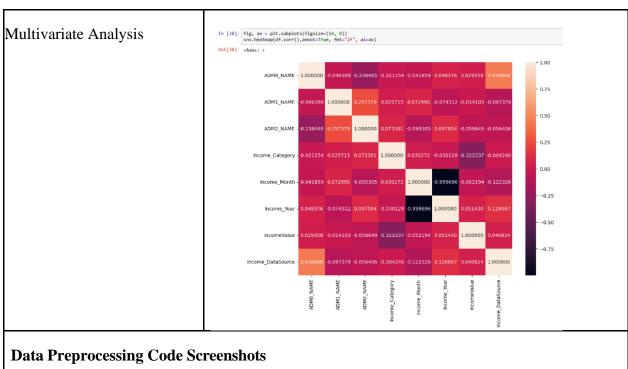
















	In [7]:	In [7]: df.describe(include-'all')									
	Out[7]:		ADM0_NAME	ADM1_NAME	ADM2_NAME	Income_Category	Income_Month	Income_Year	IncomeValue	Income_DataSource	
		count	4370	4022	444	4349	4370.000000	4370.000000	4370	4345	
		unique	32	363	68	27	NaN	NaN	3744	32	
		top	Senegal	\$South/Amajyepfo	Lanao Del Norte	Labor - Salary/Regular	NaN	NaN	Baseline	WFP VAM Analyse Globale de la Vulnerabilite, d	
Loading Data		freq	256	54	12	370	NaN	NaN	25	256	
6		mean	NaN	NaN	NaN	NaN	18.535240	1998.965904	NaN	NaN	
		std	NaN	NaN	NaN	NaN	151.007077	150.455385	NaN	NaN	
		min	NaN	NaN	NaN	NaN	1.000000	0.350877	NaN	NaN	
		25%	NaN	NaN	NaN	NaN	5.000000	2009.000000	NaN	NaN	
		50%	NaN	NaN	NaN	NaN	7.000000	2010.000000	NaN	NaN	
		75%	NaN	NaN	NaN	NaN	9.000000	2012.000000	NaN	NaN	
		max	NaN	NaN	NaN	NaN	2009.000000	2014.000000	NaN	NaN	
Handling Missing Data											
Feature Engineering	Attac	Attached the codes in final submission.									
Save Processed Data	-										